

Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio)

Game Market Evolution - Construção de Pipeline de Dados de Jogos Eletrônicos (1980-2024)

Nome: Guilherme de Araújo Peixoto da Silva

Matrícula: 4052026000190

Data: 27/09/2026

Dataset: Video Game Sales & Industry Data (1980-2024), Kaggle, licença CC0

Tipo de Projeto: Pipeline de Dados (ELT) em Arquitetura Medallion sobre Delta Lake no Databricks

Repositório: <https://github.com/SilentRaccoon98/game-market-evolution>

Sprint: Engenharia de Dados (40530010057_20260_01)

1. Definição do Problema (Etapas 2 e 4.1 - Contexto de Negócios e Perguntas)

1.1 Descrição do Problema

A indústria de jogos eletrônicos opera com volumes crescentes de dados de mercado (vendas por região e plataforma, notas de crítica, histórico de franquias) e decisões de estúdio (plataforma de lançamento, região de marketing, ciclo de vida de franquias) dependem diretamente da confiabilidade desses números. O problema deste MVP é de natureza de engenharia de dados: transformar um arquivo CSV bruto de 64 mil registros, com problemas típicos de fonte aberta (datas mal preenchidas, valores "Unknown", 81 variantes de nomes de plataforma, 225 duplicatas), em camadas de dados confiáveis que permitam responder a perguntas de negócio com SQL simples e auditável.

O pipeline foi construído na arquitetura medallion (bronze, silver e gold) sobre Delta Lake no Databricks Free Edition. A camada bronze preserva os dados como chegaram, acrescidos de linhagem; a silver aplica regras de padronização nomeadas (R1-R8); a gold materializa um esquema estrela (fato + 5 dimensões) e uma view que servem às consultas de negócio.

O dataset utilizado é o *"Video Game Sales & Industry Data (1980-2024)"* (Kaggle, Bhushan Divekar), composto por 64.016 registros de jogos entre 1980 e 2024 (janela efetiva dos dados: 1971-2019, com cauda em 2020+), contendo título, plataforma, gênero, publicadora, desenvolvedora, nota crítica (0-10) e vendas mundiais e regionais em milhões.

1.2 Objetivo do MVP

Construir, de ponta a ponta e de forma reproduzível, um pipeline de dados na nuvem (Databricks, Unity Catalog, Delta Lake) sobre o mercado mundial de jogos eletrônicos 1980-2024, e responder criticamente as seguintes perguntas de negócio:

1. Como a dominância de plataformas e a distribuição regional do mercado evoluíram ao longo das décadas?

- Quais consoles dominaram cada década, e com que fatia das vendas daquele período?
- Como as vendas se distribuíram entre as regiões (América do Norte, Japão, PAL e demais) em cada década?

2. Quem concentrou o mercado nos anos 2000 e 2010?

- Quais combinações de gênero × publicadora mais venderam entre 2010 e 2019?
- Qual é a fatia de mercado do top 5 de publicadoras nos anos 2000 em comparação com os anos 2010?

3. A crítica afeta vendas?

- Qual é a venda média por faixa de nota crítica (escala 0-10)?
- Entre os jogos com nota 9 ou acima, quais formam o top 100 por vendas?

Regra adotada no escopo: nenhuma pergunta pode ser removida porque o dado não comporta a resposta completa. Limitações da fonte são quantificadas (tamanho da população sobre a qual a

resposta vale) e discutidas nas seções Qualidade de dados, Solução do problema proposto e Pontos de melhoria.

2. Detalhamento do Projeto

Dados e ferramentas selecionadas

Para responder os questionamentos propostos, a fonte de dados escolhida foi:

- **Video Game Sales & Industry Data (1980-2024)**, Kaggle (Bhushan Divekar). Arquivo único de 64.016 registros de jogos lançados entre 1980 e 2024, com vendas mundiais e regionais em milhões, nota crítica (0-10) e metadados de lançamento (plataforma, gênero, publicadora, desenvolvedora, data). Licença CCO 1.0 Universal (domínio público).

O projeto proposto foi executado inteiramente na plataforma Databricks em sua versão Free Edition. Dessa forma, os scripts foram desenvolvidos em notebooks Python e, posteriormente, na etapa de análise de dados, as tabelas foram consultadas em SQL. A abordagem adotada é ELT com modelagem dimensional, sem componente preditivo: o valor do projeto está na confiabilidade e na rastreabilidade do dado, não em acurácia de modelo. Todo o código fica disponível no repositório público indicado no cabeçalho.

É importante destacar algumas limitações devido ao uso da versão Free Edition: o não agendamento de recorrência da pipeline de dados e a não possibilidade de integração direta entre Databricks e GitHub. Para a limitação de agendamento, uma possível alternativa seria a utilização do Databricks em nuvem paga com a orquestração via Workflows; quanto à integração com o GitHub, foi aplicada como alternativa o export manual dos notebooks para o repositório público do projeto. Além dessas duas, duas restrições do ambiente moldaram decisões concretas da execução: o compute serverless best-effort interrompeu uma célula da carga da bronze por preemption (a reexecução resolveu, com o Delta garantindo a consistência da tabela) e o modo Spark Connect não registra o prefixo volumes://, de modo que a leitura do arquivo de origem foi feita pelo caminho /Volumes/<catálogo>/<schema>/<volume>/<arquivo>.

O Unity Catalog veio pré-configurado na conta; foi criado o catálogo dedicado mvp_jogos com os schemas bronze, silver e gold, e um volume mvp_jogos.bronze.volumes_jogos para o arquivo de origem:

Componente	Configuração
Plataforma	Databricks Free Edition (Unity Catalog gerenciado)
Armazenamento	Delta Lake (managed tables + volume)
Catálogo	mvp_jogos (schemas bronze / silver / gold)
Volume	mvp_jogos.bronze.volumes_jogos
Arquivo de origem	Video Games Sales (1980-2024) - Raw.csv (~8,3 MB)
SHA-256 do arquivo	33780cc77d2395d82628c6f9120cc0905355a4804d5616dee06bdae414aff0d1

O código completo ficou organizado no repositório público:

Onde encontrar	Descrição
01_bronze_ingestao.ipynb	Ingestão + linhagem (SHA-256) + carga Delta
02_silver_limpeza.ipynb	Regras R1-R8 + dedup + perfil de qualidade
03_gold_modelagem.ipynb	Esquema estrela + view + queries e gráficos
relatorio.pdf	As 6 queries de negócio comentadas
relatorio.pdf	Catálogo campo a campo (7 tabelas)
relatorio.pdf	29 figuras: prints da plataforma e saídas das queries
README.md	Apresentação do projeto e instruções de reprodução

A reprodutibilidade foi validada na prática, e não apenas declarada: executar, na ordem, os notebooks 01_bronze_ingestao, 02_silver_limpeza (incluindo a célula de perfil de qualidade) e 03_gold_modelagem (incluindo as células de gráficos) em um workspace Free Edition com o CSV enviado ao volume reproduz o pipeline completo, e reexecuções devolvem o mesmo tableId e o mesmo sizeInBytes no DESCRIBE DETAIL do fato, além das mesmas chaves substitutas (seção Modelagem de dados).




Figura 1 - Workspace do Databricks ao final do projeto

Coleta e carregamento de dados (Etapa 4.2 - Carga dos Dados)

A coleta foi deliberadamente simples: **download pontual de um arquivo estático pelo portal do Kaggle, sem API**. Como o dataset é um snapshot (não uma fonte atualizada continuamente), uma única captura documentada é suficiente para o escopo e é perfeitamente reproduzível.

A licença do dataset é **CC0 1.0 Universal (domínio público)**: <https://creativecommons.org/publicdomain/zero/1.0/>, uso irrestrito, inclusive comercial, sem atribuição

obrigatória. A documentação formal da licença (exigência do curso) foi gravada em coluna própria do pipeline (Tabela 1).

O arquivo de origem foi enviado ao volume diretamente pela interface do Catalog Explorer (Figura 2).




Figura 2 - Arquivo CSV no volume `mvp_jogos.bronze.volumes_jogos`

Para tornar a reproduzibilidade provável e não apenas declarada, o **SHA-256 do arquivo como recebido** foi calculado e carimbado em **todas as linhas** da camada bronze, junto com URL da fonte, método de captura e timestamp de ingestão. Abaixo, tem-se as células do notebook 01 que definem o carimbo de linhagem e persistem a tabela em Delta (Figura 3):




Figura 3 - Células de linhagem (SHA-256 por linha) e persistência em Delta na camada bronze

Description

The table contains sales data for video games, including details such as title, platform, genre, and sales figures across different regions. It can be used for analyzing trends in video game sales, comparing performance among different genres and publishers, and understanding market dynamics over time. Additionally, it includes metadata that can support data provenance and assessment of data quality.

Filter columns...

AI generate

Column	Type	Popul...	Comment	Tags	Column masking	
img	string					
title	string					
console	string					
genre	string					
publisher	string					
developer	string					
critic_score	string					
total_sales	string					
na_sales	string					
jp_sales	string					
pal_sales	string					
other_sales	string					
release_date	string					
last_update	string					
arquivo_origem	string					
fonte_origem	string					
url_fonte	string					
licenca	string					
metodo_coleta	string					
formato_origem	string					

1

2

>

Figura 4 - Tabela bronze.vgsales_raw no Catalog Explorer (22 colunas)

Table

+

	 img	 title	 console	 genre	 publisher	 develop
1	/games/boxart/full_6510540AmericaFrontcccj...	Grand Theft Auto V	PS3	Action	Rockstar Games	Rockstar Noi
2	/games/boxart/full_5563178AmericaFrontcccj...	Grand Theft Auto V	PS4	Action	Rockstar Games	Rockstar Noi
3	/games/boxart/827563ccc.jpg	Grand Theft Auto: Vice City	PS2	Action	Rockstar Games	Rockstar Noi
4	/games/boxart/full_9218923AmericaFrontcccj...	Grand Theft Auto V	X360	Action	Rockstar Games	Rockstar Noi
5	/games/boxart/full_4990510AmericaFrontcccj...	Call of Duty: Black Ops 3	PS4	Shooter	Activision	Treyarch

Figura 5 - Preview dos primeiros registros da camada bronze


Em sequência, a validação da contagem da camada (Figura 6), idêntica ao número de linhas do arquivo de origem.



	total_linhas	jogos_unicos	consoles_distintos	generos_distintos	publishers_distintos
1	64016	39798	81	20	3383

Figura 6 - Contagem da camada bronze

O DESCRIBE DETAIL devolve format = delta (Figura 7), a prova material de que a tabela é transacional (ACID). O mesmo comando é repetido na silver e na gold (seção Modelagem de dados).



```
%sql
DESCRIBE DETAIL mvp_jogos.bronze.vgsales_raw
```

	format	id	name	description	location	created
1	delta	eb428d3d-07d9-422f-868c-792aee584200	mvp_jogos.bronze.vgsales_r...	null		2026-09-23

Figura 7 - DESCRIBE DETAIL da bronze: format = delta

O pacote do Kaggle traz um segundo arquivo, Video_Games_Sales_Cleaned.csv, já "limpo". Ele **não foi utilizado**: limpeza produzida por processo não documentado é exatamente o tipo de problema que um pipeline medallion existe para evitar. A limpeza deste projeto acontece na camada silver, com regras nomeadas e auditáveis (seção Modelagem de dados).

Modelagem de dados (Etapa 4.3 - Modelagem e Catálogo de Dados)

Após realizar a ingestão do arquivo em camada bronze, os dados passaram pelos seguintes processos de padronização na camada silver:

- **R1 (higiene textual)**: trim e colapso de espaços múltiplos em todas as strings.
- **R2 (coerção numérica estrita)**: somente valores que casam com o padrão numérico vira double; o resto vira NULL. Vendas negativas e notas fora do domínio [0, 10] (R2b) também viram NULL; a decisão registrada é a estriteza: NULL honesto em vez de valor interpretado à força.
- **R3 (datas)**: parse de dd-MM-yyyy para date; o que não parseia, fica NULL.
- **R4 (ausência ≠ valor)**: "Unknown" em publisher e developer vira NULL. Uma publicadora "Unknown" é a *ausência* da informação, não um valor; tratá-la como tal poluiria qualquer agregação.
- **R5 (mapeamento de consoles)**: 72 valores curados para nomes canônicos e famílias (PlayStation, Nintendo, Xbox, PC, Mobile, Sega, Atari, Arcade, Multiplataforma, Outro); os demais caem em fallback documentado (nome original preservado, família "Outro"). O mapeamento foi **persistido como tabela** (silver.map_console, 72 linhas), pois mapeamento é dado e se audita no catálogo, não apenas no código.

- **R6 (flags de qualidade):** tem_dados_vendas, tem_notas_critica, ano_lancamento, data_aproximada (datas 01-01 e 31-12), genero_generico ("Misc") e img_placeholder (boxart padrão). As flags permitem filtrar sem destruir linhas.
- **R7 (deduplicação):** 225 pares duplicados por (título, console) no arquivo original; a dedup mantém a linha mais informativa por critério em cascata.
- **R8 (grupo EA):** EA Sports, EA Games e EA recebem a marcação "Electronic Arts (grupo)" em coluna à parte; a publicação original é preservada.

A manipulação de deduplicação (R7), que decide qual linha duplicada permanece, foi implementada com uma janela ordenada pelos cinco critérios em cascata (célula do notebook 02 abaixo):



```

# deduplicação por (título, console_original)
# mantém a linha mais informativa: com vendas > com nota > maior
# total_sales > maior critic > last_update mais recente.
w = Window.partitionBy("título", "console_original").orderBy(
    F.col("tem_dados_vendas").desc(),
    F.col("tem_notas_critica").desc(),
    F.col("total_sales_mio").desc_nulls_last(),
    F.col("critic_score").desc_nulls_last(),
    F.col("last_update").desc_nulls_last(),
)

df_s = (df_s.withColumn("_rn", F.row_number().over(w))
        .filter("_rn = 1").drop("_rn"))

```

df_s: pyspark.sql.connect.dataframe.DataFrame = [console_original: string, título: string ... 29 more fields]

Figura 8 - Célula da deduplicação (R7) na camada silver

Dessa forma, obtemos a tabela silver.jogos_vendas com 31 colunas tipadas e **63.791 linhas** (as 64.016 originais menos as 225 duplicatas), sem perda de outras linhas. O DESCRIBE DETAIL confirma format = delta; a Figura 9 mostra a tabela no catálogo, a Figura 10, a contagem antes e depois da limpeza, e a Figura 11, o preview com os tipos já coercoados: date nas datas, double nas vendas, boolean nas flags.

Description 

The table contains data related to video game sales and their attributes. It includes information on various consoles, titles, developers, genres, and publishers, along with sales data across different regions. Use cases for this table include analyzing trends in video game sales, comparing the performance of different titles or genres, and studying the impact of critic scores on sales. The data can also support historical analysis regarding game releases and sales performance over time.

AI generate

Column	Type	Popul...	Comment	Tags	Column masking	
console_original	string					
titulo	string					
developer	string					
genero	string					
publisher	string					
critic_score	double					
total_sales_mio	double					
na_sales_mio	double					
jp_sales_mio	double					
pal_sales_mio	double					
other_sales_mio	double					
release_date	date					
last_update	date					
img	string					
data_ingestao	timest...					
arquivo_origem	string					
fonte_origem	string					
url_fonte	string					
licenca	string					
metodo_coleta	string					

1
2
>

Figura 9 - Tabela silver.jogos_vendas no Catalog Explorer

Table 							   	
	 linhas_bronze	 linhas_silver	 duplicatas_removal	 com_vendas	 com_nota	 datas_aprox		
1	64016	63791	225	18860	6665	563		

Figura 10 - Linhas antes (64.016) e depois (63.791) da limpeza, com as 225 duplicatas

	tr	gênero	publisher	1.2 critic_score	1.2 total_sales_mio	1.2 na_sales_mio	1.2 jp_sales_mio
1		Strategy	Ving	null	null	null	null
2		Sports	Sega	null	null	null	null
3	ct2	Role-Playing	Namco Bandai	6.2	0.23	0.11	null
4	ct2	Role-Playing	Namco Bandai	5.7	0.17	null	0.17
5		Misc	Quinrose	null	0.01	null	0.01

5 rows 4.856s runtime Refreshed at 9/23/26, 6:21 PM (4d ago)

Figura 11 - Preview da silver tipada

A construção das tabelas em camada gold faz com que o modelo se organize em **esquema estrela**: um fato de vendas e cinco dimensões, com granularidade de uma linha por jogo por plataforma: GTA V, por exemplo, aparece quatro vezes (uma por console), o que é o que a pergunta 1 exige. Abaixo, foi realizada a representação do modelo relacional com as cardinalidades (Figura 12):



Figura 12 - Representação do esquema estrela (fato + 5 dimensões) com cardinalidades

As decisões de modelagem adotadas foram:

- **Chaves substitutas determinísticas**, em vez do `monotonically_increasing_id` comum em tutoriais: reexecutar o pipeline gera as mesmas chaves, e o gold fica reproduzível em vez de renumerável a cada carga. O método utilizado foi a função `pmid` sobre o hash das colunas de negócio, definida na primeira célula do notebook 03 (Figura 13):



```
# constantes e helper
from pyspark.sql import functions as F

SILVER = "mvp_jogos.silver.jogos_vendas"
G      = "mvp_jogos.gold."
MOD    = 2147483647 # 2^31 - 1

def sk(*cols):
    """Chave substituta determinística (reproduzível em re-execuções)."""
    return F.pmod(F.hash(F.concat_ws("\u0001", *cols)), MOD).cast("int")

df_s = spark.table(SILVER)
```

> df_s: pyspark.sql.connect.dataframe.DataFrame = [console_original: string, titulo: string ... 29 more fields]

Figura 13 - Célula da chave substituta determinística (sk) na camada gold

- **Dimensões sem NULL:** quando a publicadora é desconhecida, o fato guarda `publisher_id = NULL`; a ausência de dado não é uma dimensão.
- **critic_score como medida semiaditiva:** vive no fato, mas só pode ser agregada por média, pois soma de notas não é medida válida.
- **dim_calendario sem gap-filling:** contém apenas os anos presentes no dado (51 anos entre 1971 e 2024, com lacunas), com coluna decada e a flag dentro_janela_vendas (1980-2024, janela declarada do dataset).

A contagem da camada gold fecha com **63.791 linhas no fato, idêntico à silver**, confirmação de que os cinco joins não inflaram nem perderam linha. O DESCRIBE DETAIL do fato confirma `format = delta`, e a view `gold.v_jogo_vendas` (estrela achatada com as chaves de negócio das dimensões) foi criada como ponto único de consulta das perguntas de negócio (Figuras 14 e 15).

Description 

The schema organizes data related to video games and their sales. It contains tables for genres, publishers, consoles, and games, along with sales data that includes regional performance metrics and critical scores. This structure supports analysis of market trends, sales performance, and publisher dynamics in the gaming industry.

Tables 7
Volumes 0
Models 0
Functions 0
Secrets 0
Services 0
Skills 0

Connections 0

Sort ▾

Name	Owner	Created at	Popularity	Comment
 dim_calendario	gui_gm98@hotm...	Sep 23, 2026, 07:0...		The table contains...
 dim_console	gui_gm98@hotm...	Sep 23, 2026, 06:4...		The table contains...
 dim_genero	gui_gm98@hotm...	Sep 23, 2026, 06:5...		The table contains...
 dim_jogo	gui_gm98@hotm...	Sep 23, 2026, 06:4...		The table contains...
 dim_publisher	gui_gm98@hotm...	Sep 23, 2026, 06:5...		The table contains...
 fato_vendas_jogo	gui_gm98@hotm...	Sep 23, 2026, 07:0...		The table contains...
 v_jogo_vendas	gui_gm98@hotm...	Sep 25, 2026, 10:1...		The table contains...

Figura 14 - Tabelas gold no Catalog Explorer (fato + 5 dimensões)

Table ▾	+					
	¹ ₃ jogo_console_id	¹ ₃ jogo_id	^A _C titulo	^A _C developer	¹ ₃ console_id	^A _C console_origi
1	402833534	180130961	""Nuke It""	CrystalVision	119940003	PC
2	1627874622	1692074556	"100 Washitsu ""room escape game""	null	127568198	And
3	606629197	1197735240	"10101: ""Will"" the Starship"	Sound Technology	341998214	PS

Figura 15 - Amostra da view v_jogo_vendas

Catálogo de dados (Etapa 4.3)

1. bronze.vgsales_raw

Coluna	Tipo	Descrição
img	string	Caminho da boxart do jogo
title	string	Título do jogo
console	string	Plataforma, como veio da fonte
genre	string	Gênero
publisher	string	Publicadora ("Unknown" em ~14% das linhas)
developer	string	Desenvolvedora ("Unknown" em

		~7%)
critic_score	string	Nota crítica 0-10 (ausente em ~90%)
total_sales	string	Vendas mundiais (mi)
na_sales / jp_sales / pal_sales / other_sales	string	Vendas regionais (mi)
release_date	string	Data de lançamento, dd-MM-yyyy (imprecisa em parte)
last_update	string	Última atualização na fonte (72% vazia)
data_ingestao	timestamp	Carimbo de tempo da carga
arquivo_origem / fonte_origem / url_fonte	string	Linhagem: origem do dado
licenca / metodo_coleta / formato_origem	string	Linhagem: termos e método de captura
checksum_sha256	string	SHA-256 do arquivo original, em cada linha

Tabela 1 - Catálogo de dados da tabela bronze.vgsales_raw (64.016 linhas, 22 colunas)

2. silver.jogos_vendas

Coluna	Tipo	Regra	Descrição
titulo	string	R1	Título
developer	string (NULL)	R1+R4	Desenvolvedora; NULL quando "Unknown"
console_original	string	R1	Plataforma como veio da fonte
console_canonico	string	R5	Nome canônico do console
familia_plataforma	string	R5	Família (PlayStation, Nintendo, ...)
genero	string	R1	Gênero
publisher	string (NULL)	R1+R4	Publicadora; NULL quando "Unknown"
publisher_grupo	string (NULL)	R8	Agrupamento do grupo EA
critic_score	double (NULL)	R2+R2b	Nota crítica, domínio [0,10]
total_sales_mio ... other_sales_mio	double (NULL)	R2	Vendas mundiais e regionais (mi), ≥ 0
release_date	date (NULL)	R3	Data de lançamento
ano_lancamento	int (NULL)	R6	Ano derivado da data
data_aproximada	boolean	R6	true para 01-01 / 31-12
last_update	date (NULL)	R3	72% NULL (revisado pelo perfil na seção Qualidade de dados)
img	string	R1	Caminho da boxart
img_placeholder	boolean	R6	true para boxart padrão
tem_dados_vendas / tem_nota_critica	boolean	R6	Flags de presença de dado
genero_generico	boolean	R6	true para gênero "Misc"
(8 colunas de linhagem)	n/a	n/a	Herdadas da bronze,

			intactas
--	--	--	----------

Tabela 2 - Catálogo de dados da tabela silver.jogos_vendas (63.791 linhas, 31 colunas)

3. silver.map_console

Coluna	Tipo	Descrição
console_original	string	Chave natural; sigla/código da fonte
console_canonico	string	Nome canônico
familia_plataforma	string	Família da plataforma
regra	string	"mapeamento curado (72 valores)"

Tabela 3 - Catálogo de dados da tabela silver.map_console (72 linhas)

4. gold.fato_vendas_jogo

Coluna	Tipo	Descrição
jogo_console_id	int	Chave primária (determinística)
jogo_id / console_id / genero_id / publisher_id / ano_id	int	FKs para as dimensões (publisher_id e ano_id admitem NULL)
vendas_total_mio ... vendas_other_mio	double	Medidas aditivas de vendas (mi)
critic_score	double	Medida semiaditiva (média, nunca soma)
tem_dados_vendas / tem_notas_criticas / data_aproximada / img_placeholder	boolean	Flags de qualidade
data_ingestao / checksum_sha256	n/a	Linhagem preservada até o final

Tabela 4 - Catálogo de dados da tabela gold.fato_vendas_jogo (63.791 linhas)

5. Dimensões gold

Dimensão	Linhas	Colunas
dim_jogo	39.788	jogo_id, titulo, developer
dim_console	81	console_id, console_original, console_canonico, familia_plataforma
dim_genero	20	genero_id, genero, genero_generico
dim_publisher	3.381	publisher_id, publisher, publisher_grupo
dim_calendario	51	ano_id (1971-2024, com lacunas), decada, dentro_janela_vendas

Tabela 5 - Dimensões da camada gold

Nota sobre dim_publisher (3.381 linhas): o arquivo original trazia variantes de caso de "Unknown" ("Unknown", "unknown"...), que convergiram para NULL na silver (R4), reduzindo o total de publicadoras distintas em relação à contagem crua.

6. Dimensões gold — catálogo campo a campo

Coluna	Tipo	Descrição
dim_jogo.jogo_id	int	Chave substituta (hash do título)
dim_jogo.titulo	string	Título do jogo; chave natural da dimensão
dim_jogo.developer	string	Estúdio (mín. lexicográfico se divergente)
dim_console.console_id	int	Chave substituta (hash da sigla)
dim_console.console_original	string	Sigla/código exatamente como na fonte
dim_console.console_canonico	string	Nome canônico (de silver.map_console)
dim_console.familia_plataforma	string	PlayStation, Xbox, Nintendo, PC, Sega, Outros
dim_genero.genero_id	int	Chave substituta (hash do gênero)
dim_genero.genero	string	Gênero como na fonte (20 valores distintos)
dim_genero.genero_generico	boolean	true apenas no rótulo genérico "Misc"
dim_publisher.publisher_id	int	Chave substituta (hash da publicadora)
dim_publisher.publisher	string	Publicadora ("Unknown" vira NULL na R4)
dim_publisher.publisher_grupo	string	Grupo econômico (R8): EA, EA Games e EA Sports viram "Electronic Arts (grupo)"
dim_calendario.ano_id	int	Ano de lançamento (1971-2024, com lacunas)
dim_calendario.decada	string	Década derivada do ano ("1970" ... "2020")
dim_calendario.dentro_janela_vendas	boolean	true para $1980 \leq \text{ano} \leq 2024$

Tabela 6 - Catálogo de dados das cinco dimensões da camada gold (16 colunas)

7. gold.v_jogo_vendas (view de consumo)

Coluna	Tipo	Descrição
jogo_console_id, jogo_id, console_id, genero_id, publisher_id, ano_id	int	Chaves do fato e das dimensões (grão: um jogo em um console)
titulo, developer, console_original, console_canonico, familia_plataforma, genero, publisher, publisher_grupo, decada	string	Atributos descritivos trazidos das cinco dimensões
vendas_total_mio, vendas_na_mio, vendas_jp_mio, vendas_pal_mio, vendas_other_mio, critic_score	double	Medidas do fato; regionais e nota podem ser NULL
tem_dados_vendas, tem_nota_critica, data_aproximada, img_placeholder, dentro_janela_vendas	boolean	Flags de qualidade e janela, propagadas sem filtro
data_ingestao, checksum_sha256	n/a	Linhagem preservada até a camada de consumo

Tabela 7 - Catálogo de dados da view de consumo gold.v_jogo_vendas (63.791 linhas, 28 colunas)

A view é o objeto consultado por todas as queries da análise: achata o esquema estrela com LEFT JOIN do fato para as cinco dimensões, preserva o grão de uma linha por jogo por console e mantém flags e linhagem visíveis até o consumo. Nenhum filtro é aplicado nela: as exclusões (nota ou vendas ausentes) ficam explícitas em cada query.

Pipeline de Dados (Etapa 4.4)

O pipeline foi ramificado em três notebooks, um por camada da arquitetura medallion, em vez de concentrado em um único arquivo. A escolha não foi estética e se justifica por três motivos observados durante a própria execução. O primeiro é o isolamento de falha: o compute serverless da Free Edition é best-effort e interrompeu uma célula da carga da bronze por preemption; com as camadas separadas, bastou reexecutar o notebook 01, e o Delta garantiu que a tabela não ficasse em estado parcial. O segundo é o custo baixo de reexecução parcial: ajustes nas regras de padronização exigem rodar apenas o notebook 02, e ajustes de modelagem, apenas o 03, já que cada notebook lê a tabela da camada anterior pelo nome (spark.table) e não depende da sessão do outro. O terceiro é a legibilidade da auditoria: cada notebook corresponde a um bloco deste relatório e a um conjunto de evidências, o que torna direto verificar qual código produziu qual tabela.

O fluxo completo entre os objetos do Unity Catalog é o seguinte:

```
CSV (Kaggle)
|
v  upload manual pelo Catalog Explorer
Volume .mvp_jogos.bronze.volumes_jogos / vgsales_1980_2024_raw.csv
|
v  NOTEBOOK 01  leitura com schema integral STRING + carimbo de linhaagem
bronze.vgsales_raw ..... Delta, 64.016 linhas, 22 colunas
|
v  NOTEBOOK 02  regras R1-R8 + deduplicacao + perfil de qualidade
silver.map_console (72) --> silver.jogos_vendas ... Delta, 63.791 x 31
|
v  NOTEBOOK 03  chaves determinísticas, dimensões, fato e view
gold.dim_jogo (39.788) dim_console (81) dim_genero (20)
gold.dim_publisher (3.381) dim_calendario (51)
  \--> gold.fato_vendas_jogo ..... Delta, 63.791 linhas
        \--> view gold.v_jogo_vendas (estrela achatada)
              \--> 6 queries de negocio + 6 graficos
```

Cada etapa é um processo de ETL independente, que lê de uma tabela e grava em outra sempre com `write.format("delta").mode("overwrite").saveAsTable(...)`. A ordem de execução é estrita (01, 02 e 03) e a única dependência externa é o arquivo presente no volume. A persistência em Delta nas três camadas está evidenciada nas Figuras 4 (bronze), 9 (silver) e 14 (gold), e o caráter transacional, pelo DESCRIBE DETAIL da Figura 7. O que cada transformação faz, por que foi feita e qual o seu impacto sobre os dados estão descritos nas regras R1-R8 e nas decisões de modelagem da seção anterior: a R7, por exemplo, remove exatamente 225 linhas duplicadas, e a R4 converte em NULL as 8.808 publicadoras registradas como "Unknown".


A reprodutibilidade foi validada na prática, e não apenas declarada: executar, na ordem, os notebooks 01, 02 (incluindo a célula de perfil de qualidade) e 03 (incluindo as células de gráficos) em um workspace Free Edition com o CSV enviado ao volume reproduz o pipeline completo. Na reexecução de controle, o DESCRIBE DETAIL do fato devolveu o mesmo tableId e o mesmo sizeInBytes (757.902 bytes), as chaves substitutas permaneceram idênticas e as contagens da camada gold não se alteraram (39.788 / 81 / 20 / 3.381 / 51 / 63.791). Duas limitações do pipeline devem ser registradas desde já e voltam em Pontos de melhoria: ele roda sob demanda, sem orquestração, porque a Free Edition não oferece agendamento; e opera sobre um snapshot único, sem carga incremental.

Análise de dados (Etapa 4.5)

A etapa de análise de dados será dividida em dois momentos, sendo o primeiro dedicado à análise de qualidade da camada silver e o segundo à resposta das perguntas de negócio definidas na seção 1 do trabalho.

Qualidade de dados (Etapa 4.5)

Nessa etapa, valida-se que a camada silver está adequada para a análise de negócio. Para isso, foi executado um perfil de nulos coluna a coluna (célula de perfil do notebook 02), cujo resultado está na Figura 16 (tabela completa, 31 colunas) e no gráfico da Figura 17.



Perfil de nulos – mvp_jogos.silver.jogos_vendas (63791 linhas)

	coluna	nulos	pct_nulos
1	critic_score	57126	89.6
2	jp_sales_mio	57100	89.5
3	na_sales_mio	51184	80.2
4	pal_sales_mio	50998	79.9
5	other_sales_mio	48693	76.3
6	last_update	45958	72
7	total_sales_mio	44931	70.4
8	publisher	8808	13.8
9	publisher_grupo	8808	13.8
10	release_date	7020	11
11	ano_lancamento	7020	11
12	developer	4421	6.9
13	console_original	0	0
14	titulo	0	0
15	genero	0	0

Figura 16 - Perfil de nulos da camada silver (tabela completa, 31 colunas)




Figura 17 - Top 15 colunas da silver por % de nulos

As ausências se concentram exatamente nos campos que dependem de o mercado ter registrado a informação. Nota crítica ausente em **89,6%** das linhas; vendas, em **70,4%** no total e entre **76% e 90%** nas regionais (a regional japonesa é a mais esparca, coerente para títulos ocidentais); publisher, em **13,8%**; data de lançamento, em **11,0%**. No extremo oposto, as **15 colunas produzidas pelo próprio pipeline** (chaves, canônicos, flags e linhagem) apresentam **0,0%** de nulos. A qualidade do que o pipeline constrói fica separada e visível da qualidade do que ele recebe, o que é o propósito direto das camadas.

Pelas dimensões de qualidade DMBOK: **completude** quantificada e exposta via flags (nunca removida em silêncio); **precisão** garantida pela coerção estrita da R2; **consistência** validada no pré-profile (conferência em pandas externa ao pipeline): a soma das regionais fecha com o total em 100% das linhas com dado; garantida pelos nomes canônicos de console; **unicidade** pela dedup R7 (-225 linhas); **atualidade** pelo timestamp de ingestão; **validade** pelos domínios (nota em [0,10], vendas ≥ 0 , datas parseáveis).

A revisão da qualidade rendeu três achados documentados em vez de corrigidos em silêncio:

1. "08-Apr" como publicadora. Um valor na dimensão de publishers exigiu investigação: 08-Apr não é nome de publicadora conhecida. São três linhas, de dois jogos: *Undertale* e *Deltarune*, todas com desenvolvedor Toby Fox. A fonte upstream do dataset (VGChartz) lista o publisher desses jogos como "8-4"; em algum momento da preparação do dataset, um spreadsheet interpretou o número como data e gravou "08-Apr". A decisão registrada foi **não alterar o valor**: o impacto nas respostas é de 0,02 mi em vendas (0,001% do mercado dos anos 2010), e reescrever dado de fonte sem regra verificável seria um risco maior do que o próprio defeito. O caso fica registrado aqui e é mantido como estudo de integridade de dados.

2. last_update: expectativa inicial revisada pelo perfil. No pré-profile, a coluna havia sido classificada como "quase sempre vazia". O perfil desta seção mediu **72% de nulos, ou seja, 28% das linhas possuem**

valor, bem acima do previsto. A correção foi registrada no catálogo e importa para a dedup: o critério final do cascata R7 só é efetivo para cerca de um quarto das linhas.

3. A métrica que somava 100%. A primeira versão da query da pergunta 2.b produziu fatias que somavam exatamente 100,0% dentro do top 5; diagnóstico imediato: na ordem lógica do SQL, a janela SUM() OVER (PARTITION BY decada) do SELECT final é avaliada **após** o WHERE rn <= 5, de modo que o denominador era o próprio top 5, não o mercado. A query foi corrigida (denominador agora vem de CTE que soma o mercado total da década) e o episódio documentado. O defeito seria invisível a testes unitários; somente a auditoria das saídas, com expectativa independente, o captura.

Solução do problema proposto (Etapa 4.5 - Análise de Dados)

A partir da view v_jogo_vendas criada sobre o esquema estrela da camada gold, é possível responder às perguntas de negócio feitas na seção 1 do trabalho. As queries comentadas estão reproduzidas a seguir e correspondem, uma a uma, às células do notebook 03_gold_modelagem.

1. Como a dominância de plataformas e a distribuição regional do mercado evoluíram ao longo das décadas?

1.a) Quais consoles dominaram cada década, e com que fatia das vendas daquele período?

Para responder essa questão, somaram-se as vendas por década e console canônico e calculou-se a fatia de cada console no total da sua década:

```
WITH por_decada_console AS (
    SELECT decada, console_canonico,
           ROUND(SUM(vendas_total_mio), 1) AS vendas_mio
    FROM mvp_jogos.gold.v_jogo_vendas
    WHERE vendas_total_mio IS NOT NULL AND decada IS NOT NULL
    GROUP BY decada, console_canonico
),
top AS (
    SELECT *, ROW_NUMBER() OVER (PARTITION BY decada
                                ORDER BY vendas_mio DESC) AS rn
    FROM por_decada_console
)
SELECT decada, console_canonico, vendas_mio,
       ROUND(100.0 * vendas_mio / SUM(vendas_mio)
            OVER (PARTITION BY decada), 1) AS fatia_da_decada_pct
FROM top
WHERE rn <= 5
ORDER BY decada, vendas_mio DESC;
```

Nota de auditoria (fatia da década). A coluna fatia_da_decada_pct da Figura 18 traz a fatia de cada console **dentro do top 5**, e não dentro da década: na ordem lógica do SQL, a janela SUM(vendas_mio) OVER (PARTITION BY decada) do SELECT final é avaliada após o WHERE rn <= 5 — o mesmo defeito do achado 3 acima, aqui detectado apenas na auditoria final e com a mesma assinatura: as fatias somam 100,0% em toda década. A correção segue o padrão já aplicado na 2.b, com o denominador vindo de uma CTE que soma o mercado total da década. As fatias reais, recalculadas sobre os totais de década da Figura 20, são as usadas na discussão a seguir; o top 5 cobre 91,5% dos anos 90, 69,3% dos anos 2000 e 80,9% dos anos 2010, e a cauda fora do top 5 é, ela mesma, uma medida da fragmentação do mercado.

	A ^B década	A ^B console_canonico	1.2 vendas_mio	1.2 fatia_da_decada_pct
1	1970	Atari 2600	5.2	100
2	1980	Atari 2600	70.1	68.5
3	1980	Nintendo (NES)	32.3	31.5
4	1980	PC	0	0
5	1990	PlayStation (PS1)	391.2	66.8
6	1990	Nintendo 64	70.7	12.1
7	1990	Super Nintendo (SNES)	65.7	11.2
8	1990	Sega Saturn	33.5	5.7
9	1990	PC	24.4	4.2
10	2000	PlayStation 2	1017.8	44.2
11	2000	DS	355.7	15.5
12	2000	Xbox 360	345.9	15
13	2000	Wii	297.9	13
14	2000	PlayStation 3	282.9	12.3
15	2010	PlayStation 3	554.6	27.2

Figura 18 - Saída da query 1.a

P1a — Consoles dominantes por década




Figura 19 - Top 5 consoles por década

É possível observar o padrão de **dominação de uma plataforma por década**: Atari 2600 nos anos 70 e 80 (68,4% da década de 1980), PlayStation 1 com **61,1%** dos anos 90 (com peso dos anos 1994-99, já que o hardware só entra no mercado na metade da década), PS2 com **30,7%** dos anos 2000, até a **fragmentação dos anos 2010**, em que PS3 (22,0%), PS4 (21,4%) e Xbox 360 (20,4%) dividem praticamente o mesmo bolo, mecanismo esperado da sobreposição de gerações de hardware. A década de 2020 aparece na tabela como cauda (3,4 mi no total, 0,1% do dataset) e é excluída do gráfico por

legibilidade; a tabela a preserva. Ressalva de janela: os dados efetivos começam em 1971 e terminam de forma densa em 2019.

1.b) Como as vendas se distribuíram entre as regiões (América do Norte, Japão, PAL e demais) em cada década?

Para a distribuição regional, somaram-se as vendas regionais por década:

```
SELECT decada,
       ROUND(SUM(vendas_na_mio), 1) AS vendas_na_mio,
       ROUND(SUM(vendas_jp_mio), 1) AS vendas_jp_mio,
       ROUND(SUM(vendas_pal_mio), 1) AS vendas_pal_mio,
       ROUND(SUM(vendas_other_mio), 1) AS vendas_other_mio,
       ROUND(SUM(vendas_total_mio), 1) AS vendas_total_mio
FROM mvp_jogos.gold.v_jogo_vendas
WHERE vendas_total_mio IS NOT NULL AND decada IS NOT NULL
GROUP BY decada
ORDER BY decada;
```

	decada	1.2 vendas_na_mio	1.2 vendas_jp_mio	1.2 vendas_pal_mio	1.2 vendas_other_mio	1.2 vendas_total_mio
1	1970	4.8	null	0.3	0	
2	1980	72.7	23.9	5.1	0.8	
3	1990	287.4	188.2	138.6	25.6	
4	2000	1834.5	240.6	902.4	338.2	
5	2010	1140.4	224.1	865.2	285.3	
6	2020	0.5	2.5	0.3	0.1	

Figura 20 - Saída da query 1.b




Figura 21 - Vendas por região × década

A América do Norte domina em todas as décadas com vendas (1.834,5 mi nos anos 2000, ~55% da década). O resultado mais relevante é o **Japão: 29% das vendas dos anos 90** (188,2 de 640 mi), caindo para ~9% nos anos 2010, coerente com a força local de SNES, N64 e PS1. A região PAL cresce de 5,1 mi (anos 80) para 21,7%, 27,2% e 34,4% nas décadas seguintes. Um ponto de validação de linhagem: o total dos anos 2010 sai **2.516,3 mi** na gold, contra **2.518,9 mi** no arquivo bruto (pré-profile em pandas); a diferença de 2,6 mi corresponde exatamente às linhas duplicadas com vendas removidas pela R7. Esta reconciliação valida a rastreabilidade ponta a ponta: cada ponto de divergência entre camadas tem explicação auditável.

Assim, a evolução do mercado é lida em duas dimensões complementares: a consolidação de uma plataforma dominante por geração, fragmentada pela sobreposição de hardware nos anos 2010, e o deslocamento gradual do mercado para a América do Norte e a região PAL, com o Japão relevante nos anos 90 e em queda relativa.

2. Quem concentrou o mercado nos anos 2000 e 2010?

2.a) Quais combinações de gênero × publicadora mais venderam entre 2010 e 2019?

O recorte de 2010-2019 agrupa gênero e publicadora pelo total de vendas:

```
SELECT genero, publisher, COUNT(*) AS jogos,
       ROUND(SUM(vendas_total_mio), 1) AS vendas_mio
FROM.mvp_jogos.gold.v_jogo_vendas
WHERE ano_id BETWEEN 2010 AND 2019
      AND vendas_total_mio IS NOT NULL
      AND publisher IS NOT NULL
GROUP BY genero, publisher
ORDER BY vendas_mio DESC
LIMIT 10;
```

– P2a – Top 10 gênero × publisher (2010–2019)

	^A _C genero	^A _C publisher	¹ ₃ jogos	^{1.2} vendas_mio
1	Shooter	Activision	83	249.2
2	Sports	EA Sports	153	205.4
3	Shooter	Electronic Arts	74	117.4
4	Action	Rockstar Games	11	79.8
5	Sports	2K Sports	73	67.7
6	Action	Ubisoft	61	64.1
7	Role-Playing	Bethesda Softworks	20	50.6
8	Action	Warner Bros. Interactive Entertainment	71	48.1
9	Action-Adventu...	Ubisoft	33	46.1
10	Shooter	Ubisoft	31	39.6

Figura 22 - Saída da query 2.a




Figura 23 - Top 10 gênero × publisher (2010-2019)

O par Shooter × Activision (83 jogos, 249,2 mi), puxado pela franquia Call of Duty, lidera, seguido por Sports × EA Sports (153 jogos, 205,4 mi) e por Shooter × Electronic Arts (117,4 mi), onde pesa Battlefield. A leitura com maior valor analítico é a **eficiência por título**: Rockstar Games concentra 79,8 mi em apenas **11** jogos na janela (7,3 mi por título), enquanto EA Sports atinge 205,4 mi com 153 (1,3 mi por título): dois modelos opostos (blockbuster e volume de franquia anual) legíveis diretamente do fato.

2.b) Qual é a fatia de mercado do top 5 de publicadoras nos anos 2000 em comparação com os anos 2010?

A fatia de mercado de cada publicadora foi calculada em relação ao mercado total de cada década (e não apenas ao top 5; ver o achado 3 da seção Qualidade de dados):

```
WITH pub_decada AS (
    SELECT CASE WHEN ano_id BETWEEN 2000 AND 2009 THEN '2000s'
               WHEN ano_id BETWEEN 2010 AND 2019 THEN '2010s' END AS decada,
           publisher, SUM(vendas_total_mio) AS vendas_mio
    FROM mvp_jogos.gold.v_jogo_vendas
    WHERE vendas_total_mio IS NOT NULL
           AND publisher IS NOT NULL
           AND ano_id BETWEEN 2000 AND 2019
    GROUP BY 1, 2
),
mercado AS (
    SELECT decada, SUM(vendas_mio) AS total_mercado
    FROM pub_decada GROUP BY decada
),
top5 AS (
    SELECT decada, publisher, vendas_mio,
           ROW_NUMBER() OVER (PARTITION BY decada
                              ORDER BY vendas_mio DESC) AS rn
    FROM pub_decada
)
```

```
SELECT t.decada, t.publisher, ROUND(t.vendas_mio, 1) AS vendas_mio,
       ROUND(100.0 * t.vendas_mio / m.total_mercado, 1)
       AS fatia_do_mercado_da_decada_pct
FROM top5 t JOIN mercado m ON t.decada = m.decada
WHERE t.rn <= 5
ORDER BY t.decada, t.vendas_mio DESC;
```

– P2b – Fatia de mercado real do top-5 publishers: 2000s vs 2010s

Table ▾

+

	^A _C decada	^A _C publisher	1.2 vendas_mio	1.2 fatia_do_mercado_da_decada_pct
1	2000s	Electronic Arts	357.2	10.8
2	2000s	Activision	339.9	10.2
3	2000s	THQ	251.9	7.6
4	2000s	EA Sports	234.8	7.1
5	2000s	Ubisoft	206.7	6.2
6	2010s	Activision	348	13.9
7	2010s	Ubisoft	250.1	10
8	2010s	Electronic Arts	245.9	9.8
9	2010s	EA Sports	208.6	8.3
10	2010s	Rockstar Games	112.3	4.5

Figura 24 - Saída da query 2.b (fatias + concentração do top 5)

P2b — Concentração de publishers (top 5 por década)




Figura 25 - Concentração de publishers por década

Nos anos 2000, o top 5 controlava **≈ 42,0%** do mercado (EA 10,8%, Activision 10,2%, THQ 7,6%, EA Sports 7,1%, Ubisoft 6,2%); nos anos 2010, **≈ 46,6%** (Activision 13,9%, Ubisoft 10,0%, EA 9,8%, EA Sports 8,3%, Rockstar 4,5%). A **concentração aumentou ~4,6 pontos percentuais** em uma década, e a composição registra o evento: **THQ, terceira força dos anos 2000, desaparece nos anos 2010** (falência de 2012-13, visível nos dados sem que precisasse ser informada externamente), e Rockstar entra.

A partir das respostas 2.a e 2.b, observa-se que o mercado se concentrou no topo da indústria: a fatia do top 5 cresceu **~4,6 pontos percentuais** entre os anos 2000 e 2010, e a composição do próprio top 5

registra a consolidação do setor: a saída da THQ (falência) e a entrada da Rockstar, enquanto dentro do mercado a leitura de gênero × publicadora opõe o modelo blockbuster à estratégia de volume de franquias anuais. Duas ressalvas de leitura: o denominador é o mercado com publicadora identificada (a R4 converteu em NULL os 8.808 registros "Unknown"), e a consolidação por grupo econômico prevista na R8 não foi aplicada nesta query — somadas, Electronic Arts e EA Sports respondem por ≈ 17,9% dos anos 2000 e ≈ 18,2% dos anos 2010, liderando as duas décadas.

3. A crítica afeta vendas?

3.a) Qual é a venda média por faixa de nota crítica (escala 0-10)?

Para a relação entre crítica e vendas, calculou-se a venda média por faixa de nota, considerando apenas as linhas com os dois atributos presentes:

```
WITH base AS (
  SELECT CASE WHEN critic_score < 6 THEN '0-5'
             WHEN critic_score < 7 THEN '6-6,9'
             WHEN critic_score < 8 THEN '7-7,9'
             WHEN critic_score < 9 THEN '8-8,9'
             ELSE '9-10' END AS faixa_nota,
         critic_score, vendas_total_mio
  FROM mvp_jogos.gold.v_jogo_vendas
  WHERE critic_score IS NOT NULL
         AND vendas_total_mio IS NOT NULL
)
SELECT faixa_nota, COUNT(*) AS jogos,
       ROUND(AVG(vendas_total_mio), 3) AS venda_media_mio
FROM base
GROUP BY faixa_nota
ORDER BY MIN(critic_score);
```

- P3a - Venda média por faixa de nota crítica

Table  

	^A _C faixa_nota	¹ ₃ jogos	^{1.2} venda_media_mio
1	0-5	749	0.314
2	6-6,9	853	0.444
3	7-7,9	1188	0.577
4	8-8,9	1051	1.103
5	9-10	282	2.068

Figura 26 - Saída da query 3.a




Figura 27 - Venda média por faixa de nota

A venda média cresce de forma monotônica de **0,314 mi** (faixa 0-5, n=749) a **2,068 mi** (faixa 9-10, n=282), cerca de **6,6×** entre as extremas. O resultado é consistente com a correlação esperada entre nota e vendas, com as ressalvas que a própria pergunta exige: a análise cobre as 4.123 linhas com nota e venda simultâneas (**6,5% do dataset**); a faixa 9-10 tem amostra pequena (282); a média é sensível a outliers, e blockbusters de nota 9+ são outliers por construção; e correlação não implica causalidade (jogos de maior orçamento recebem mais críticas e mais marketing simultaneamente). Mediana e modelo de regressão foram registrados em Pontos de melhoria.

3.b) Entre os jogos com nota 9 ou acima, quais formam o top 100 por vendas?

O recorte final lista os 100 maiores vendedores entre os jogos com nota 9 ou acima:

```
SELECT titulo, console_canonico, ano_id AS ano, publisher,
       ROUND(critic_score, 1) AS critic_score,
       ROUND(vendas_total_mio, 2) AS vendas_mio
FROM.mvp_jogos.gold.v_jogo_vendas
WHERE critic_score >= 9 AND vendas_total_mio IS NOT NULL
ORDER BY vendas_mio DESC
LIMIT 100;
```

- P3b - Top 100 jogos com nota crítica >= 9

	titulo	console_canonico	ano	publisher
1	Grand Theft Auto V	PlayStation 3	2013	Rockstar Games
2	Grand Theft Auto V	PlayStation 4	2014	Rockstar Games
3	Grand Theft Auto: Vice City	PlayStation 2	2002	Rockstar Games
4	Red Dead Redemption 2	PlayStation 4	2018	Rockstar Games
5	Call of Duty: Modern Warfare 2	Xbox 360	2009	Activision
6	Grand Theft Auto III	PlayStation 2	2001	Rockstar Games
7	Grand Theft Auto IV	Xbox 360	2008	Rockstar Games
8	Call of Duty: Modern Warfare 2	PlayStation 3	2009	Activision
9	Grand Theft Auto IV	PlayStation 3	2008	Rockstar Games
10	Halo: Reach	Xbox 360	2010	Microsoft Game Studios
11	Call of Duty 4: Modern Warfare	Xbox 360	2007	Activision
12	The Elder Scrolls V: Skyrim	Xbox 360	2011	Bethesda Softworks
13	Grand Theft Auto V	Xbox One	2014	Rockstar Games
14	Battlefield 1	PlayStation 4	2016	Electronic Arts
15	Medal of Honor: Frontline	PlayStation 2	2002	Electronic Arts

Figura 28 - Saída da query 3.b (topo da lista de 100 linhas)




Figura 29 - Top 15 dos 100 jogos com nota ≥ 9

O topo é *Grand Theft Auto V* (PS3, 2013) com **20,32 mi** e nota 9.4, maior valor do recorte analisado, o que fecha um ciclo de validação: o recorte "nota ≥ 9 " capturou o recorde global, como deveria.

GTA V aparece três vezes nesta lista (nota ≥ 9); Rockstar domina o topo, e a lista registra onde crítica e caixa coincidiram: *Red Dead Redemption 2*, *Call of Duty: Modern Warfare 2*, *Skyrim*, *Assassin's Creed*, *Portal 2*, *Mass Effect*.

A partir das respostas 3.a e 3.b, a crítica afeta vendas no sentido de correlação positiva robusta (venda média 6,6× maior entre as faixas extremas, e o recorde global de vendas entre os jogos bem avaliados), com as ressalvas já declaradas: a população analisada corresponde a 6,5% do dataset, a média é sensível a outliers e a relação não é causal: a nota crítica acompanha, em boa parte, o orçamento e o marketing que também impulsionam vendas.

3. Considerações Finais

Pontos de melhoria

Uma limitação intrínseca do dado utilizado é a esparsidade das vendas e das notas críticas: as vendas estão ausentes em 70,4% das linhas (as perguntas 1 e 2 respondem sobre 18.860 jogos, 29,6% do dataset) e a nota crítica, ausente em 89,6% (a pergunta 3 responde sobre 6.665 linhas com nota, 10,4% do dataset, das quais 4.123 também têm venda). As populações sobre as quais cada resposta vale foram declaradas em cada uma delas, em vez de removê-las do escopo. Somam-se a isso 5.636 datas aproximadas (01-01 / 31-12, 8,8% do dataset, sinalizadas pela flag `data_aproximada`), a dedup case-sensitive por (título, console) e a janela efetiva de 1971-2019, com as décadas de 1970 e 2020 em amostras mínimas.

A ingestão e o tratamento não contemplaram orquestração (Workflows) nem fonte incremental: a pipeline roda sob demanda sobre um snapshot único, decisão de prazo do MVP. Uma evolução direta seria a utilização dos serviços pagos do Databricks para o agendamento das pipelines, com a gold alimentada incrementalmente por uma API de catálogo de jogos (RAWG, 20 mil requisições gratuitas por mês), e a integração com o repositório do projeto no GitHub, eliminando a etapa de export manual dos notebooks. Também é desejável que o controle de qualidade saia dos perfis univariados e das reconciliações manuais, que capturaram os três achados da seção Qualidade de dados, para testes declarativos em cada carga (expectations no estilo Delta Live Tables / Great Expectations), de modo que o defeito do tipo "métrica que soma 100%" fosse bloqueado antes da análise.

Finalmente, como o pipeline já entrega um dataset dimensionalizado e limpo, uma possível evolução para as análises apresentadas seria a incorporação de um modelo preditivo de sucesso comercial sobre a gold (vendas ~ nota, ano, plataforma, gênero, publicadora), substituindo a média por faixa de nota por uma estimativa com incerteza, incluindo a mediana, sensível a outliers, registrada como limitação da resposta 3.a. Esse modelo seria também o ponto de integração com o projeto de machine learning do portfólio (classificação de tipos de Pokémon por visão computacional, em repositório separado), unificando dados de mercado e dados visuais de jogos em um catálogo. Complementarmente, é desejável a validação cruzada com a segunda fonte histórica de vendas (vgsales 1980-2019, 16,6 mil registros), quando a questão de licença dela for resolvida, e o SCD Tipo 2 em `dim_console` e `dim_publisher` para registrar mudanças de nomenclatura ao longo do tempo.

Em síntese, o MVP respondeu as seis perguntas de negócio com dados rastreáveis do arquivo original até a camada final, em um pipeline reproduzível e persistido em Delta nas três camadas, com a qualidade medida e documentada em vez de presumida, e cada evolução listada acima já tem um ponto de partida claro no trabalho entregue.

4. Autoavaliação

Em âmbito pessoal, este foi um projeto que me tirou da zona de conforto de forma produtiva. O trabalho anterior (classificação de sprites de Pokémon por visão computacional) tratava do dado como insumo: baixar, treinar, avaliar. Neste, o dado é o trabalho: de onde veio, o que aconteceu a cada transformação, e como se prova que a linha da tabela final desceu daquele arquivo específico. Construir isso sobre uma plataforma nova (Databricks, Unity Catalog, Delta), com quatro dias de prazo e um compute best-effort que derrubou o notebook no meio do processo, exigiu priorizar cedo e auditar o tempo todo.

Frente à rubrica: o objetivo foi atingido na forma definida: as seis perguntas respondidas, nenhuma removida, limitações quantificadas. A coleta e a documentação de licença (CC0) estão formais; a modelagem e o catálogo ficaram completos, campo a campo; o pipeline está reproduzível e persistido em Delta; a qualidade foi tratada com perfil coluna a coluna e três achados documentados com decisão registrada; a análise combina SQL, gráficos e leitura de negócio. O ponto fraco que eu mesmo apontaria é o mesmo registrado em Pontos de melhoria: o controle de qualidade ficou concentrado em perfis univariados e reconciliações manuais, sem testes declarativos e sem orquestração: escolhas de escopo que pagam uma conta que este relatório assume explicitamente.

A avaliação mais honesta, porém, é prática: antes deste projeto, o Databricks e o Delta Lake eram ferramentas de desconfiança; depois, cada prova (o `format = delta` do `DESCRIBE DETAIL`, o hash por linha, o self-check de contagem 63.791 entre silver e gold) tem nome, lugar no pipeline e função. É a base sobre a qual o trabalho preditivo da seção Pontos de melhoria será construído.

5. Referências

- Divekar, B. *Video Game Sales & Industry Data (1980 - 2024)*. Kaggle, licença CC0 1.0 Universal.
<https://www.kaggle.com/datasets/bhushandivekar/video-game-sales-and-industry-data-1980-2024>
- Creative Commons. *CC0 1.0 Universal - Public Domain Dedication*.
<https://creativecommons.org/publicdomain/zero/1.0/>
- Databricks. *Unity Catalog, Volumes e Delta Lake, documentação oficial*.
<https://docs.databricks.com>
- VGChartz. *Undertale: vendas por plataforma* (fonte do achado "8-4"/"08-Apr").
<https://www.vgchartz.com/game/220354/undertale/>
- DAMA International. *Data Management Body of Knowledge (DMBOK2)*: dimensões de qualidade de dados.